Machine_Learning_Prototyp

November 14, 2018

Prototypisierung des theoretischen Konzeptes

Das Vorgehen der Prototypisierung richtet sich an die Phasen des CRISP-DM Prozessmodells. Die beiden Phasen Business Understanding und Deployment werden dabei nicht für die praktische Umsetzung berücksichtigt, da diese Phasen Aufgaben der betrieblichen Praxis enthalten. Somit sind sie für die Demonstration der Funktionen nicht relevant. Die aufgestellten Use Cases sind den Phasen Data Understanding, Data Preperation, Modeling und Evaluation zugeordnet.

Data Understanding

- UC02 Datensatz laden
- UC03 Datensatz beschreiben
- UC04 Daten visualisieren

```
In [1]: # for dealing with large datasets
       import pandas as pd
       # for processing multidimensional arrays
       import numpy as np
       # for importing functions from another notebook
       import import_ipynb
       # notebook with the logic for data generation
       import Data_Generator
       # show all visual outputs directly in the Jupyter notebook
       %matplotlib inline
importing Jupyter notebook from Data_Generator.ipynb
In [2]: from sklearn.utils import shuffle
       # shuffle generated data and load it into a data frame
       df = shuffle(Data_Generator.generate_data_set(5000))
       # show first five entries of the shuffled data frame
       df.head()
Out[2]:
            Duration Region
                                 Km Stops Weather Extreme Traffic
       4074 2.75581 1 2.68609 11
                                             none 26.6477
```

758	4.75395	3	14.3729	48	none	88.5243
1417	4.08024	4	17.9515	98	none	18.2974
4537	4.49769	3	14.6012	69	none	89.1568
3248	7.09394	5	17.5022	138	snow	96.1133

Um ein besseres Verständnis über die Daten zu erhalten, erfolgt eine Beschreibung des Datensatzes. Für jede Spalte mit numerischen Werten werden folgende Eigenschaften berechnet und angezeigt:

- Anzahl an Einträgen
- Mittelwert
- Standardabweichung
- Kleinster Wert
- 25%-Perzentil
- Median
- 75%-Perzentil
- Größter Wert

```
In [3]: # convert numeric columns for description
        df['Duration'] = pd.to_numeric(df['Duration'])
        df['Region'] = pd.to_numeric(df['Region'])
        df['Km'] = pd.to_numeric(df['Km'])
        df['Stops'] = pd.to_numeric(df['Stops'])
        df['Traffic'] = pd.to_numeric(df['Traffic'])
        # describe for each numerical column:
        # number of entries,
        # number of unique values,
        # standard deviation,
        # min, max value,
        # lower percentile, upper percentile,
        # median
        df.describe()
Out[3]:
                  Duration
                                                              Stops
                                                                          Traffic
                                  Region
                                                    Km
               5000.000000
                             5000.000000
                                           5000.000000
                                                        5000.000000
                                                                      5000.000000
        count
        mean
                  4.765207
                                3.013200
                                             10.907766
                                                          62.333000
                                                                        50.411542
                                                          41.431904
                                                                        28.609584
        std
                  1.659467
                                1.419235
                                              5.736581
                  0.793058
                                1.000000
                                              0.011009
                                                           1.000000
                                                                         0.021689
        min
        25%
                  3.475378
                                2.000000
                                              5.764785
                                                          20.000000
                                                                        25.877859
        50%
                  4.772899
                                3.000000
                                                          60.000000
                                             11.160588
                                                                        50.691117
        75%
                  6.031007
                                4.000000
                                             15.763333
                                                         101.000000
                                                                        75.161896
```

Für Spalten mit nicht numerischen Werten wird folgendes berechnet und angezeigt:

5.000000

Anzahl an Einträgen

max

• Anzahl an einzigartigen Werten

9.067503

• meist vorkommender Wert

19.993932

140.000000


99.997895

• Häufigkeit des am meisten vorkommenden Wertes

Um Einblick in die Verteilung und die Beziehung zwischen den Daten zu erlangen, bietet sich die Visualisierung des Datenbestandes an. Hierfür werden die Beziehungen der einzelnen Merkmalspaare in einer scatter plot matrix dargestellt.

```
In [5]: import seaborn as sns

# visualize a scatter plot matrix
# different colors stands for weather values
splom = sns.pairplot(df, hue = "Weather Extreme")
```



Data Preperation

758

• UC05 - Daten transformieren

4.753949

1417 4.080244

Für nicht numerische Werte muss eine Einzelattributstransformation durchgeführt werden, damit die Lernalgorithmen diese in die Berechnung einbeziehen können. Im Fall der generierten Daten muss dies nur für das Wetter durchgeführt werden.

3 14.372939

17.951528

4

48 88.524295

98 18.297396

1

1

4537	4.497689	3 14.	601206	69	89.156768	1
3248	7.093945	5 17.	502232	138	96.113309	0
	Weather Extre	me_rain	Weather	Extre	me_snow	
4074		0			0	
758		0			0	
1417		0			0	
4537		0			0	
3248		0			1	

Modeling

- UC06 Testdesign erstellen
- UC07 Hyperparameter kalibrieren
- UC08 Validierungskurven visualisieren
- UC09 Modelle trainieren
- UC10 Trainingszeiten berechnen
- UC11 Trainingszeiten visualisieren
- UC12 Entscheidungsbaum visualisieren

Zunächst wird definiert, welcher Wert vorhergesagt werden soll und welche Prädikatoren dafür verwendet werden.

```
In [7]: # define label --> target value, which should be predicted
    y = df["Duration"]
    # define features/ variables for predicting the label
    X = df.drop(["Duration"], axis = 1)
```

Im nachfolgendem Schritt wird ein Testdesign erstellt. Dafür werden die Daten in Trainings- und Testdaten aufgeteilt. Zum Testen der Vorhersagequalität werden die Modelle mit den Trainingsdaten trainiert und mit den Testdaten getestet. Um repräsentativere Ergebnisse über die Qualität zu erhalten, wird eine 10-fold cross validation durchgeführt.

Es werden vier Regressionsalgorithmen zum Lernen der Beziehungen zwischen den Daten verwendet:

• Lineare Regression

- Bayesian Regression
- Support Vector Regression
- Decision Tree Regression

```
In [9]: # load algorithms from scikit learn libary
        from sklearn.linear_model import LinearRegression
        from sklearn.linear_model import BayesianRidge
        from sklearn.svm import SVR
        from sklearn.tree import DecisionTreeRegressor
        # initialize models
        lr = LinearRegression()
        br = BayesianRidge()
        svr = SVR()
        dtr = DecisionTreeRegressor()
        # define model names
        model_names = (
            'Lineare Regression',
            'Bayesian Regression',
            'Support Vector Regression',
            'Decision Tree Regression'
        )
        # function to get the name of a model for printing
        # Oparam model_var: model for which the name is searched
        # @return switcher.get(): name of the model
        def get_model_name(model_var):
            switcher = {
                lr:model_names[0],
                br:model_names[1],
                svr:model_names[2],
                dtr:model_names[3]
            }
            return switcher.get(model_var, "Invalide model")
```

Für die Support Vector Regression und die Decision Tree Regression werden die Hyperparameter auf optimale Werte kalibriert. Für die anderen beiden Methoden entfällt die Optimierung aufgrund der geringeren Komplexität der Algorithmen. Das Ändern der Parameter würde sich im Ergebnis kaum bis gar nicht bemerkbar machen.

Damit die Findung eines optimalen Wertes für einen Hyperparameter nachvollzogen werden kann, wird die folgende Funktion verwendet, um die validation curve zu visualisieren.


```
# Oparam param: hyperparameter which should be optimized
# Oparam param_range: values for the hyperparameter
def draw_val_curve(model, param, param_range):
    # calculate validation curves
   train_scores, test_scores = validation_curve(
        model,
       Х,
       у,
       param_name = param,
       param_range = param_range
    )
    # print train score for each parameter value in the range
    print("Train Scores: " + str(np.mean(train_scores, axis = 1)))
    # print test score for each parameter value in the range
    print("Test Scores: " + str(np.mean(test_scores, axis = 1)))
    # set title of the diagram
    plt.title(param + '-Validierung')
    # label y axis
   plt.ylabel('Genauigkeit')
    # label x axis
    plt.xlabel('Parameter Werte')
    # draw curve of average training scores for each value in the range
    plt.plot(param_range, np.mean(train_scores, axis = 1), color = 'black',
       label = 'Training Data')
    # draw curve of average test scores for each value in the range
    plt.plot(param_range, np.mean(test_scores, axis = 1), linestyle='dashed',
       color = 'black', label = 'Test Data')
    # draw a legend for the both curves
    plt.legend()
    # show graph
    plt.show()
```

Mit der nächsten Funktion wird eine grid search zur empirischen Findung der optimalen Werte für die Hyperparameter der Support Vector Regression implementiert.


```
("scaler", StandardScaler()),
                 ("svr", svr_model)
             1)
             # GridSearch for the pipeline with the hyperparameters and the values for them
             gsCV = GridSearchCV(pipeline, param_grid = {
                 "svr__C": [0.1, 0.5, 1.0, 1.5, 2.0, 2.5],
                 "svr_epsilon": [0.0, 0.5, 1.0, 1.5, 2.0],
                 "svr_kernel": ['rbf','linear']
             })
             # fit the data to the GridSearch as a model
             gsCV.fit(X,y)
             # print best values for the hyperparameters
             print("Bester Wert für SVR-Hyperparameter: " + str(gsCV.best_params_))
             # set best values as parameters for the Support Vector Regression model
             svr_model.C = gsCV.best_params_["svr__C"]
             svr_model.epsilon = gsCV.best_params_["svr__epsilon"]
             svr_model.kernel = gsCV.best_params_["svr__kernel"]
In [12]: # call function to find the best values for the hyperparameters
         find_best_svr_params(svr)
Bester Wert für SVR-Hyperparameter:
{'svr_C': 2.5, 'svr_epsilon': 0.5, 'svr_kernel': 'linear'}
```

Für den C, epsilon und kernel Parameter wird eine validation curve erstellt.


Je geringer die Genauigkeitswerte auf der y-Achse sind, desto höher ist der Bias. Wenn der Bias hoch ist, konnten die Zusammenhänge in den Daten nicht erkannt werden, weshalb die Vorhersageleistung abnimmt. In diesem Fall ist von einer Unteranpassung des Modells zu sprechen. Je weiter die Kurven für die Trainings- und Testergebnisse auseinander gehen, desto höher ist die Varianz. Das Modell ist in diesem Fall zu komplex geworden, weshalb es sich zu sehr an die Trainingsdaten angepasst hat.



Train Scores: [0.93717043 0.88763834 0.75938633 0.58283479 0.39325996] Test Scores: [0.71923343 0.67785072 0.57385061 0.43646789 0.29479446]




Train Scores: [0.93580508 0.8805365]
Test Scores: [0.71683665 0.88005764]



Für die Decision Tree Regression werden ebenfalls optimale Werte für die Hyperparameter per grid search gesucht.


```
})
             # fit the data to the GridSearch as a model
             gsCV.fit(X,y)
             # print best values for the hyperparameters
             print("Bester Wert für DTR-Hyperparameter: " + str(gsCV.best_params_))
             # set best values as parameters for the Decision Tree Regression model
             dtr_model.max_depth = gsCV.best_params_["dtr__max_depth"]
             dtr_model.max_leaf_nodes = gsCV.best_params_["dtr__max_leaf_nodes"]
             dtr_model.min_weight_fraction_leaf =
                gsCV.best_params_["dtr__min_weight_fraction_leaf"]
In [15]: # call function to find the best values for the hyperparameters
         find_best_dtr_params(dtr)
Bester Wert für DTR-Hyperparameter:
{'dtr_max_depth': 5, 'dtr_max_leaf_nodes': None, 'dtr_min_weight_fraction_leaf': 0.0}
In [16]: # call function to visualize the validation curve for the hyperparameters
         draw_val_curve(
                DecisionTreeRegressor(), "max_depth", np.array([1, 3, 5, 7, 9])
         )
         draw_val_curve(
                DecisionTreeRegressor(), "max_leaf_nodes", np.array([2, 3, 4, 5, 6, 8, 9, 20])
         )
         draw_val_curve(
                DecisionTreeRegressor(), "min_weight_fraction_leaf",
                 np.array([0.0, 0.1, 0.2, 0.3, 0.4, 0.5])
         )
Train Scores: [0.57469735 0.81413222 0.88105713 0.90229685 0.93043298]
Test Scores: [0.56027153 0.81096092 0.87509956 0.86475797 0.83751204]
```




0.83214582 0.87235625]

Test Scores: [0.56027153 0.68003188 0.71739253 0.75619697 0.77778223 0.81209406

0.82972405 0.86855594]




Train Scores: [1. 0.81011469 0.69772463 0.6330373 0.56676264 0.15077473]
Test Scores: [0.76595063 0.80329457 0.69172239 0.62771334 0.5760224 0.1502103]



Die nächsten beiden Funktionen sind zur Anpassung der Modelle an die Trainingsdaten. Die Zeiten, die zum Trainieren benötigt werden, werden dabei gemessen und vergleichend in einem Balkendiagramm dargestellt.

```
In [17]: from timeit import default_timer as timer
         # function to calculate the time which a model needs to fit the data
         # Oparam model: model which should be trained
         # @return tt: training time
         def calculate_training_time(model):
             # start the measurement of the training time
             start = timer()
             # train the model with the test data
             model.fit(X_train, y_train)
             # stop the measurement of the training time
             end = timer()
             # calculate the time from start to end
             tt = end - start
             # print the training time of the model
             print("Trainingszeit der " + get_model_name(model) + ": " + str(tt))
             # return the training time
             return tt
         # function to draw a bar graph of the training times
         # Oparam values: calculated training times of all models
         def draw_training_times(values):
             # create a figure
             fig,ax = plt.subplots()
             # set title
             plt.title('Trainingszeiten')
             # label y axis
             plt.ylabel('t in s')
             # set limits for the y axis
             y_pos = np.arange(len(model_names))
             plt.ylim(0,max(values))
             # draw bars
             plt.bar(y_pos, values, align='center', alpha=0.85, color='black')
```

```
# print names of the models
             ax.set_xticks(range(len(model_names)))
             ax.set_xticklabels(model_names, rotation='45')
             # show graph
             plt.show()
             #plt.savefig('election_presidentielle.png')
In [18]: # fit models to the train data and calculate training times
         lr_tt = calculate_training_time(lr)
         br_tt = calculate_training_time(br)
         svr_tt = calculate_training_time(svr)
         dtr_tt = calculate_training_time(dtr)
         # call function to draw the graph of the training times
         draw_training_times([lr_tt, br_tt, svr_tt, dtr_tt])
Trainingszeit der Lineare Regression: 0.0029520837067703496
Trainingszeit der Bayesian Regression: 0.006219597783209506
Trainingszeit der Support Vector Regression: 45.81353799254207
Trainingszeit der Decision Tree Regression: 0.0055067005368059085
```



Beim Entscheidungsbaum besteht der Vorteil, dass er auf einer Struktur und auf keiner Anpassungsfunktion basiert. Somit kann eine Vorhersage besser nachvollzogen werden. Aus diesem Grund wird der generierte Entscheidungsbaum textuell und im Anschluss grafisch ausgegeben.

```
1 -> 2;
3 [label="Traffic <= 25.151\nmse = 0.458\nsamples = 374\nvalue = 2.236"];
2 \rightarrow 3;
4 [label="Weather Extreme_snow <= 0.5\nmse = 0.395\nsamples = 182\nvalue = 1.954"];
5 [label="mse = 0.259\nsamples = 118\nvalue = 1.818"];
6 [label="mse = 0.548 \times = 64 \times = 2.204"];
4 -> 6;
7 [label="Weather Extreme_snow <= 0.5\nmse = 0.371\nsamples = 192\nvalue = 2.503"];
3 \to 7;
8 [label="mse = 0.26 \times = 132 \times = 2.351"];
7 -> 8;
9 [label="mse = 0.453\nsamples = 60\nvalue = 2.838"];
7 -> 9 ;
10 [label="Traffic <= 74.641\nmse = 0.413\nsamples = 365\nvalue = 3.165"];
2 \rightarrow 10;
11 [label="Weather Extreme_none <= 0.5\nmse = 0.317\nsamples = 198\nvalue = 2.889"];
10 -> 11 ;
12 [label="mse = 0.315 \times = 121 \times = 3.049"];
11 -> 12 ;
13 [label="mse = 0.217 \times = 77 \times = 2.636"];
11 -> 13 ;
14 [label="Weather Extreme_snow <= 0.5\nmse = 0.328\nsamples = 167\nvalue = 3.493"];
10 -> 14 ;
15 [label="mse = 0.221 \times = 120 \times = 3.335"];
14 -> 15 ;
16 [label="mse = 0.375 \times = 47 \times = 3.896"];
14 -> 16 ;
17 [label="Traffic \leq 50.1 \times = 0.65 \times = 751 \times = 3.731"];
1 -> 17 ;
18 [label="Traffic <= 24.572\nmse = 0.374\nsamples = 382\nvalue = 3.238"];
17 -> 18 ;
19 [label="Weather Extreme_none <= 0.5\nmse = 0.326\nsamples = 182\nvalue = 2.992"];
18 -> 19 ;
20 [label="mse = 0.318\nsamples = 124\nvalue = 3.108"];
19 -> 20 ;
21 [label="mse = 0.254\nsamples = 58\nvalue = 2.745"];
19 -> 21 ;
22 [label="Weather Extreme_none <= 0.5\nmse = 0.312\nsamples = 200\nvalue = 3.462"];
18 -> 22 ;
23 [label="mse = 0.337 \times = 118 \times = 3.587"];
24 [label="mse = 0.221\nsamples = 82\nvalue = 3.283"];
22 -> 24 ;
25 [label="Traffic <= 74.528\nmse = 0.424\nsamples = 369\nvalue = 4.241"];
17 -> 25 ;
26 [label="Weather Extreme_none <= 0.5\nmse = 0.363\nsamples = 184\nvalue = 3.995"];
```

```
25 -> 26 ;
27 [label="mse = 0.397\nsamples = 128\nvalue = 4.114"];
26 -> 27 ;
28 [label="mse = 0.179\nsamples = 56\nvalue = 3.724"];
26 -> 28 :
29 [label="Weather Extreme_snow <= 0.5\nmse = 0.364\nsamples = 185\nvalue = 4.486"];
25 -> 29 ;
30 [label="mse = 0.287 \times 10^{-2}];
29 -> 30 ;
31 [label="mse = 0.317 \times = 61 \times = 4.857"];
29 -> 31 ;
32 [label="Region \leq 4.5 \times 1.336 \times 1.
0 -> 32 [labeldistance=2.5, labelangle=-45, headlabel="False"] ;
33 [label="Region <= 3.5\nmse = 0.878\nsamples = 1500\nvalue = 5.269"] ;
32 -> 33 ;
34 [label="Traffic <= 49.206\nmse = 0.645\nsamples = 732\nvalue = 4.771"] ;
33 -> 34 ;
35 [label="Traffic \leq 24.988 \times = 0.439 \times = 338 \times = 4.25];
34 -> 35 ;
36 [label="mse = 0.341 \times = 169 \times = 3.978"];
35 -> 36 ;
37 [label="mse = 0.388 \times = 169 \times = 4.523"];
35 -> 37 ;
38 [label="Traffic <= 74.914 \times = 0.39 \times = 394 \times = 5.218"];
34 -> 38 ;
39 [label="mse = 0.372 \times = 205 \times = 5.041"];
38 -> 39 ;
40 [label="mse = 0.339\nsamples = 189\nvalue = 5.41"];
38 -> 40 ;
41 [label="Traffic \leq 50.1\nmse = 0.639\nsamples = 768\nvalue = 5.743"];
33 -> 41 ;
42 [label="Traffic <= 24.404\nmse = 0.379\nsamples = 399\nvalue = 5.277"] ;
41 -> 42 ;
43 [label="mse = 0.314\nsamples = 182\nvalue = 5.044"];
42 -> 43 ;
44 [label="mse = 0.35\nsamples = 217\nvalue = 5.473"] ;
42 -> 44 ;
45 [label="Traffic <= 75.343 \times = 0.432 \times = 369 \times = 6.247"];
41 -> 45 ;
46 [label="mse = 0.3\nsamples = 198\nvalue = 5.978"];
45 -> 46;
47 [label="mse = 0.405 \times = 171 \times = 6.558"];
45 -> 47 ;
48 [label="Traffic <= 49.882\nmse = 0.707\nsamples = 760\nvalue = 6.788"];
32 -> 48 ;
49 [label="Traffic <= 24.825\nmse = 0.411\nsamples = 362\nvalue = 6.226"];
48 -> 49 ;
50 [label="Weather Extreme_snow <= 0.5\nmse = 0.382\nsamples = 184\nvalue = 5.985"];
```

```
49 -> 50 ;
51 [label="mse = 0.283\nsamples = 126\nvalue = 5.828"];
50 -> 51 ;
52 [label="mse = 0.427 \times = 58 \times = 6.325"];
50 -> 52 :
53 [label="Weather Extreme_none <= 0.5\nmse = 0.32\nsamples = 178\nvalue = 6.475"];
49 -> 53 ;
54 [label="mse = 0.333\nsamples = 122\nvalue = 6.593"];
53 -> 54 ;
55 [label="mse = 0.194\nsamples = 56\nvalue = 6.217"];
53 -> 55 ;
56 [label="Traffic <= 76.22\nmse = 0.426\nsamples = 398\nvalue = 7.3"];
48 -> 56 ;
57 [label="Stops <= 130.5\nmse = 0.356\nsamples = 191\nvalue = 7.023"];
56 -> 57 ;
58 [label="mse = 0.335 \times = 143 \times = 7.119"];
57 -> 58 ;
59 [label="mse = 0.308 \times = 48 \times = 6.735"];
57 -> 59 ;
60 [label="Weather Extreme_none <= 0.5\nmse = 0.354\nsamples = 207\nvalue = 7.555"];
56 -> 60 ;
61 [label="mse = 0.356 \times = 139 \times = 7.701"];
62 [label="mse = 0.219\nsamples = 68\nvalue = 7.257"];
60 -> 62;
}
In [20]: import graphviz
        # visualize the decision tree in a tree
         graphviz.Source(tree)
        # for saving the decision tree as png use the following code
        #src = graphviz.Source(tree, format = "png")
        #src.render("./dtr")
```


Evaluation

- UC13 Kennzahlen berechnen
- UC14 Ergebnisse der Kennzahlen visualisieren
- UC15 Lernkurven visualisieren
- UC16 Lieferdauer vorhersagen

Zur Evaluierung werden im ersten Schritt Metriken zur Qualitätsmessung implementiert. Dabei werden die Kennzahlen R2 (Bestimmtheitsmaß), mean squared error, root mean squared error und mean absolute error berechnet. Die Ergebnisse werden danach für die Algorithmen vergleichend in einem Balkendiagramm dargestellt.

```
In [21]: # function to calculate quality scores
         # @param model: model which should be tested
         # Oparam metric: metric to test the model
         # Oreturn score: calculated metric score
         def evaluate_model(model, metric):
             # print model name
             print(get_model_name(model) + ": ")
             # check if the metric is mse, rmse, mae
             # these metrics returns negative values
             # more infos on: https://qithub.com/scikit-learn/scikit-learn/issues/2439
             if metric.find("neg") == 0:
                 # calculate metric score and use 10-fold cross validation
                 # reverse sign
                 scores = -cross_val_score(model, X, y, cv = kf, scoring = metric)
             else:
                 # calculate metric score and use 10-fold cross validation
                 scores = cross_val_score(model, X, y, cv = kf, scoring = metric)
             # print the scores from the 10-fold cross validation
             print(scores)
             # print average score
             score = np.mean(scores)
             print("Durchschnittswert: " + str(score) + '\n')
             # return the calculated score
             return score
         # function to draw a bar graph of the evaluation results
         # Oparam title: title of the graph
         # Oparam ylabel: label for the y axis
         # Oparam values: calculated evaluation results
         def draw_metric_scores(title, ylabel, values):
             # create a figure
             fig,ax = plt.subplots()
             # set title
             plt.title(title)
             # label y axis
             plt.ylabel(ylabel)
             # set limits for the y axis
```

```
y_pos = np.arange(len(model_names))
             # R2 score has another range
             if title == '$R^2$':
                 plt.ylim(0, 1)
                 #plt.ylim(min(values) - 0.01, 1)
             else:
                 plt.ylim(0,max(values))
             # draw bars
             plt.bar(y_pos, values, align='center', alpha=0.85, color='black')
             # print names of the models
             ax.set_xticks(range(len(model_names)))
             ax.set_xticklabels(model_names, rotation='45')
             # show graph
             plt.show()
In [22]: # calculate R2 scores for each model
        lr_r2 = evaluate_model(lr, 'r2')
         br_r2 = evaluate_model(br, 'r2')
         svr_r2 = evaluate_model(svr,'r2')
         dtr_r2 = evaluate_model(dtr, 'r2')
         # call function to draw the graph of the R^2 scores
         draw_metric_scores(
                '$R^2$ Scores', 'Bestimmtheitsmaß $R^2$', [lr_r2, br_r2, svr_r2, dtr_r2]
         )
Lineare Regression:
[0.87795861 0.87082261 0.87498539 0.87654339 0.87783813 0.88868104
 0.88212928 0.88378808 0.88710123 0.88097002]
Durchschnittswert: 0.8800817780166457
Bayesian Regression:
[0.87797123 \ 0.87079174 \ 0.8749844 \ 0.87656568 \ 0.87784822 \ 0.88867149
0.88216331 0.88380428 0.88707612 0.88093918]
Durchschnittswert: 0.8800815657723546
Support Vector Regression:
[0.87800177 0.87040586 0.87502528 0.87628202 0.87787608 0.88896472
0.88225714 0.88378651 0.88728618 0.880758 ]
Durchschnittswert: 0.8800643550688996
Decision Tree Regression:
[0.87311745 0.86954007 0.86592385 0.86894264 0.87081951 0.88913215
```



calculate MSE for each model
lr_mse = evaluate_model(lr,'neg_mean_squared_error')
br_mse = evaluate_model(br,'neg_mean_squared_error')
svr_mse = evaluate_model(svr,'neg_mean_squared_error')
dtr_mse = evaluate_model(dtr,'neg_mean_squared_error')

call function to draw MSEs
draw_metric_scores(
 'MSE Scores', 'Mean Squared Error', [lr_mse, br_mse, svr_mse, dtr_mse]br

In [23]: from sklearn.metrics import mean_squared_error

)

Lineare Regression:

 $[0.34520732\ 0.35672566\ 0.35325251\ 0.3033616\ 0.33173735\ 0.31432621$

0.3261642 0.32491924 0.31525353 0.32393514]

Durchschnittswert: 0.32948827619298116

Bayesian Regression:

 $[0.3451716 \quad 0.3568109 \quad 0.3532553 \quad 0.30330682 \quad 0.33170995 \quad 0.31435319$

0.32607002 0.32487395 0.31532367 0.32401907]

Durchschnittswert: 0.329489447099134

Support Vector Regression:

 $\begin{bmatrix} 0.34508523 & 0.35787651 & 0.3531398 & 0.30400384 & 0.3316343 & 0.3135252 \end{bmatrix}$

0.32581038 0.32492364 0.3147371 0.32451216]


Durchschnittswert: 0.3295248170146045

Decision Tree Regression:


 $\begin{bmatrix} 0.35890104 \ 0.3602674 & 0.37885762 \ 0.32203841 \ 0.35079681 \ 0.31305243 \end{bmatrix}$

0.3276022 0.32659128 0.33372628 0.32882724]

Durchschnittswert: 0.3400660708305701



```
In [24]: from math import sqrt
         # calculate RMSE for each model
         lr_rmse = sqrt(lr_mse)
         print(model_names[0] + ": " + str(lr_rmse))
         br_rmse = sqrt(br_mse)
         print(model_names[1] + ": " + str(br_rmse))
         svr_rmse = sqrt(svr_mse)
         print(model_names[2] + ": " + str(svr_rmse))
         dtr_rmse = sqrt(dtr_mse)
         print(model_names[3] + ": " + str(dtr_rmse))
         # call function to draw RMSEs
         draw_metric_scores(
                'RMSE Scores', 'Root Mean Squared Error', [lr_rmse, br_rmse, svr_rmse, dtr_rmse]
         )
Lineare Regression: 0.5740106934482851
Bayesian Regression: 0.5740117133814727
Support Vector Regression: 0.5740425219568708
Decision Tree Regression: 0.5831518420022097
```



Lineare Regression:

[0.47786181 0.48242529 0.49330886 0.44354722 0.47460802 0.45678307 0.46982187 0.46926471 0.46344591 0.47249068]

Durchschnittswert: 0.47035574359490767

Bayesian Regression:

 $\hbox{\tt [0.47788278\ 0.48246118\ 0.49331617\ 0.44351759\ 0.47458964\ 0.4568135] }$

0.46968065 0.4692944 0.46354377 0.47254856]

Durchschnittswert: 0.47036482406734254

Support Vector Regression:

 $[0.47772384 \ 0.48314421 \ 0.4930058 \ \ 0.4441468 \ \ 0.4747677 \ \ 0.45555087]$

0.46951309 0.46892785 0.462723 0.47254279]


Durchschnittswert: 0.47020459425006045

Decision Tree Regression:

 $\begin{bmatrix} 0.49182565 & 0.49056163 & 0.50156561 & 0.46144784 & 0.4903602 & 0.44691778 \end{bmatrix}$

0.46617427 0.47143554 0.47367179 0.46980214]


Durchschnittswert: 0.47637624425177255





Im nächsten Schritt werden für alle Modelle die Lernkurven visualisiert. Durch die Darstellung lässt sich für jeden Algorithmus abschätzen, wie sich die Größe des Trainingssatzes auf die


Genauigkeit der Vorhersagen auswirkt.

```
In [26]: from sklearn.model_selection import learning_curve
         # function to visualize the learning curve for a model
         # Oparam: model for which the learning curve should be visualized
         def draw_learning_curve(model):
             # calculate learning curve
             train_sizes_abs, train_scores, test_scores = learning_curve(model, X, y)
             # set title of the diagram
             plt.title('Learning Curve' + '\n' + get_model_name(model))
             # label y axis
             plt.ylabel('Genauigkeit')
             # label x axis
             plt.xlabel('Trainingsgröße')
             # draw curve of average training scores for each training size
             plt.plot(
                train_sizes_abs, np.mean(train_scores, axis = 1), label='Train Data',
                color='black'
             # draw curve of average test scores for each training size
             plt.plot(
                train_sizes_abs, np.mean(test_scores, axis = 1), linestyle='dashed',
                label='Test Data', color='black'
             # draw a legend for the both curves
             plt.legend()
             # show graph
             plt.show()
In [27]: # call function to visualize the learning curve for each model
         draw_learning_curve(lr)
         draw_learning_curve(br)
         draw_learning_curve(svr)
         draw_learning_curve(dtr)
```









Im finalen Schritt kann eine Vorhersage der Zustelldauer mit jedem Modell berechnet werden. Dies wird für einen Datensatz aus dem Testset durchgeführt, welcher den Modellen unbekannt ist. Dieser wurde beim Training nicht einbezogen. Die Ergebnisse der Vorhersagen der Modelle werden tabellarisch verglichen. Zudem wird die Differenz zwischen dem berechneten und dem korrekten Wert errechnet und dargestellt.

```
# fill rows
add_row(lr)
add_row(br)
add_row(svr)
add_row(dtr)

# print results in a table
print(table)
```

+		++
Berechneter Wert	korrekter Wert	Differenz
7.376	8.267	0.891
7.378	8.267	0.889
7.374	8.267	0.893
7.701	8.267	0.566
	Berechneter Wert 	Berechneter Wert korrekter Wert